

Iterative Refinement for Vietnamese News Summarization

Bùi Thanh Lâm^{1,2,3}, Lê Trọng Tuấn Kiệt^{1,2,3}, Nguyễn Tấn Hoàng Phước^{1,2,4}

¹Khoa Khoa học và Kỹ thuật Thông tin

²Trường Đại học Công nghệ Thông tin, ĐHQG-HCM, Việt Nam

³{23520828, 21521041}@gm.uit.edu.vn, ⁴phuocnht@uit.edu.vn

Tóm tắt nội dung—Trong bối cảnh bùng nổ thông tin hiện nay, việc nắm bắt nhanh nội dung cốt lõi từ lượng tin tức tiếng Việt khổng lồ hàng ngày đang trở thành một thách thức lớn. Các phương pháp tóm tắt một lần (one-pass model) truyền thống thường bộc lộ những nhược điểm cố hữu, khi cách tiếp cận Extractive khiến các câu tóm tắt bị rời rạc, thiếu tính liên kết, còn mô hình Abstractive lại dễ mắc lỗi Hallucination (Ảo giác) hoặc bỏ sót ý chính từ văn bản gốc. Để khắc phục, đề án đề xuất quy trình Iterative Refinement dựa trên cơ chế vòng lặp phản hồi (Feedback Loop) bao gồm ba giai đoạn: sử dụng mô hình PhoBERT để lọc các câu quan trọng nhất, dùng mô hình ViT5 để biên tập lại đoạn văn trôi chảy, và cuối cùng là sự tham gia của Mô hình LLM trong vai trò bộ đánh giá (Evaluator) để tinh chỉnh bản tóm tắt qua tối đa 3 vòng lặp. Thử nghiệm trên bộ dữ liệu chuẩn VietNews với khoảng đã chứng minh tính hiệu quả của hệ thống khi cải thiện chỉ số ROUGE đồng thời nâng cao tính trung thực (Faithfulness) thêm so với các mô hình thông thường. Kết quả này khẳng định ưu thế của việc kết hợp mô hình Hybrid và khả năng của LLM trong việc tự động hóa quá trình chuẩn hóa, nâng cao chất lượng tóm tắt văn bản tiếng Việt.

1. Introduction

Trong kỷ nguyên số, sự phát triển nhanh chóng của các nền tảng truyền thông trực tuyến đã dẫn đến sự gia tăng vượt bậc về số lượng tin tức được sản xuất và phân phối mỗi ngày. Đối với người dùng, đặc biệt trong bối cảnh thông tin tiếng Việt ngày càng đa dạng và phân mảnh, việc nhanh chóng nắm bắt nội dung cốt lõi từ các bài báo dài trở thành một nhu cầu thiết yếu. Tóm tắt văn bản tự động (automatic text summarization) vì thế đóng vai trò quan trọng trong việc hỗ trợ tiếp cận thông tin, giảm tải nhận thức và nâng cao hiệu quả xử lý tri thức.

Tuy nhiên, bài toán tóm tắt tin tức vẫn đặt ra nhiều thách thức, đặc biệt đối với các ngôn ngữ ít tài nguyên như tiếng Việt. Với đặc trưng là một ngôn ngữ đơn lập, phụ thuộc mạnh vào ngữ cảnh và cấu trúc câu linh hoạt, tiếng Việt đòi hỏi các hệ thống tóm tắt không chỉ giữ được thông tin quan trọng mà còn phải đảm bảo tính mạch lạc và tự nhiên của văn bản đầu ra. Trong thực tế, nhiều mô hình được thiết kế và tối ưu chủ yếu cho tiếng Anh thường không đạt hiệu quả tương đương khi áp dụng trực tiếp cho tiếng Việt.

Các phương pháp tóm tắt hiện nay có thể được chia thành hai hướng tiếp cận chính: extractive và abstractive. Phương

pháp extractive tập trung vào việc lựa chọn các câu quan trọng nhất từ văn bản gốc, do đó đảm bảo được tính trung thực về mặt thông tin. Tuy nhiên, các câu được trích xuất thường thiếu sự liên kết, dẫn đến bản tóm tắt rời rạc và kém mạch lạc. Ngược lại, các phương pháp abstractive cho phép mô hình diễn đạt lại nội dung theo cách tự nhiên hơn, nhưng lại dễ gặp phải hiện tượng hallucination, tức là sinh ra thông tin không tồn tại trong văn bản nguồn hoặc làm sai lệch các thực thể quan trọng. Bên cạnh đó, phần lớn các mô hình hiện tại vẫn hoạt động theo cơ chế one-pass generation, trong đó tóm tắt được sinh ra chỉ trong một lần suy luận duy nhất, không có cơ chế tự đánh giá và chỉnh sửa.

Nhận thấy những hạn chế trên, nghiên cứu này đề xuất một hướng tiếp cận dựa trên tinh chỉnh lặp lại (iterative refinement) nhằm nâng cao chất lượng tóm tắt tin tức tiếng Việt. Thay vì coi việc sinh tóm tắt là một quá trình đơn bước, hệ thống được thiết kế theo tư duy tương tự như cách con người viết: tạo bản nháp, đánh giá và chỉnh sửa. Cụ thể, nghiên cứu kết hợp ưu điểm của cả hai hướng extractive và abstractive thông qua một pipeline nhiều giai đoạn, đồng thời tận dụng sức mạnh của các mô hình ngôn ngữ lớn (LLMs) như một bộ đánh giá tự động để cung cấp phản hồi và điều hướng quá trình tinh chỉnh.

Các đóng góp chính của nghiên cứu có thể được tóm lược như sau: (i) đề xuất một framework hybrid cho bài toán tóm tắt tin tức tiếng Việt, kết hợp extractive summarization, abstractive generation và iterative refinement; (ii) xây dựng cơ chế feedback loop dựa trên LLM nhằm tự động đánh giá và cải thiện bản tóm tắt mà không cần can thiệp thủ công; và (iii) tiến hành đánh giá thực nghiệm toàn diện trên bộ dữ liệu VietNews, cho thấy sự cải thiện rõ rệt cả về mặt định lượng lẫn định tính so với các mô hình one-pass truyền thống.

Phần còn lại của báo cáo được tổ chức như sau. Phần 2 trình bày các nghiên cứu liên quan trong lĩnh vực tóm tắt văn bản. Phần 3 mô tả chi tiết phương pháp đề xuất. Phần 4 trình bày thiết lập thực nghiệm và kết quả đánh giá. Cuối cùng, Phần 5 đưa ra kết luận và hướng phát triển trong tương lai.

2. Related Work

Mặc dù các phương pháp extractive và abstractive đã đạt được nhiều tiến bộ đáng kể, phần lớn các nghiên cứu hiện tại vẫn xem quá trình tóm tắt như một bài toán *one-pass generation*, trong đó mô hình chỉ sinh ra một bản tóm tắt duy nhất mà không có cơ chế tự đánh giá hay tự chỉnh sửa. Cách tiếp cận này khiến các lỗi về thiếu thông tin, dư thừa chi tiết

hoặc *hallucination* khó được phát hiện và khắc phục, đặc biệt đối với các mô hình abstractive dựa trên Transformer.

Gần đây, sự xuất hiện của các Large Language Models (LLMs) đã thúc đẩy một hướng nghiên cứu mới: sử dụng mô hình ngôn ngữ như một **evaluator tự động** để đánh giá và tinh chỉnh đầu ra. Các nghiên cứu theo hướng này coi LLM không chỉ là một bộ sinh văn bản mà còn là một critic có khả năng đánh giá chất lượng tóm tắt dựa trên các tiêu chí ngữ nghĩa cấp cao như độ bao phủ thông tin, tính trung thực (faithfulness) và độ mạch lạc (coherence). Thông qua cơ chế phản hồi (feedback), bản tóm tắt được cải thiện dần qua nhiều vòng lặp, hình thành nên quy trình *iterative refinement*.

Một số công trình tiêu biểu áp dụng mô hình *LLM-LLM*, trong đó một LLM sinh bản tóm tắt ban đầu và một LLM khác (hoặc chính nó ở vai trò khác) thực hiện đánh giá và đề xuất chỉnh sửa. Cách tiếp cận này cho thấy hiệu quả rõ rệt trong việc nâng cao chất lượng văn bản sinh, đặc biệt trong các tác vụ yêu cầu khả năng suy luận phức tạp. Tuy nhiên, việc phụ thuộc hoàn toàn vào LLM dẫn đến chi phí tính toán cao, khó kiểm soát hành vi mô hình và hạn chế khả năng triển khai ở quy mô lớn, nhất là đối với các ngôn ngữ có tài nguyên hạn chế.

Trong bối cảnh đó, đề tài này mở rộng hướng nghiên cứu evaluator-based summarization theo cách tiếp cận **LLM-SLM (Small Language Model)**. Cụ thể, LLM chỉ đóng vai trò evaluator và điều phối quá trình tinh chỉnh, trong khi nhiệm vụ sinh tóm tắt chính được thực hiện bởi mô hình ViT5 – một mô hình Seq2Seq được huấn luyện chuyên biệt cho tiếng Việt. LLM được sử dụng để đánh giá bản tóm tắt trung gian và đưa ra các hành động tinh chỉnh có cấu trúc (ví dụ: REMOVE các câu nhiễu, ADD thông tin bị thiếu), tạo thành một vòng lặp *Draft* $\rightarrow$ *Evaluate* $\rightarrow$ *Refine*.

Cách tiếp cận này vừa kế thừa ưu điểm của iterative refinement trong việc cải thiện chất lượng tóm tắt, vừa giảm đáng kể chi phí và sự phụ thuộc vào LLM so với các mô hình LLM-LLM thuần túy. Đồng thời, việc sử dụng evaluator dựa trên LLM giúp khắc phục hạn chế của các metric tự động truyền thống như ROUGE, vốn chưa phản ánh đầy đủ các khía cạnh ngữ nghĩa cấp cao. Do đó, pipeline hybrid được đề xuất không chỉ phù hợp với bối cảnh tiếng Việt mà còn có tiềm năng mở rộng sang các miền dữ liệu chuyên biệt như y tế hoặc pháp luật.

3. Methodology

3.1. Extractive Module

3.1.1. Bài toán và động cơ. Trong bối cảnh tóm tắt tin tức tiếng Việt, hầu hết các bộ dữ liệu lớn (bao gồm VietNews) **không cung cấp nhãn extractive ở mức câu**. Do đó, việc huấn luyện mô hình extractive đòi hỏi một cơ chế **tạo nhãn giả (pseudo-labeling)** từ các bản tóm tắt tham chiếu dạng abstractive.

Cách tiếp cận này tuân theo hướng nghiên cứu của *A Unified Model for Extractive and Abstractive Summarization using Inconsistency Loss*, trong đó nhãn extractive được suy ra bằng cách tối ưu mức độ bao phủ thông tin của tập câu được chọn so với summary tham chiếu.

3.1.2. Hàm đánh giá câu (Sentence Gain Function). Các phương pháp trước đây thường sử dụng **ROUGE-L Recall** làm tiêu chí chính để đo mức độ đóng góp của một câu. Tuy nhiên, ROUGE chỉ dựa trên **khớp từ bề mặt (lexical overlap)**, dẫn đến hạn chế trong các trường hợp đồng nghĩa hoặc diễn đạt khác nhau.

Để khắc phục vấn đề này, chúng tôi kết hợp thêm **BERTScore**, một metric đo **semantic similarity** dựa trên contextual embeddings, nhằm đánh giá mức độ tương đồng ngữ nghĩa giữa câu ứng viên và summary tham chiếu.

Cụ thể, gain của một câu s_i được định nghĩa như sau:

$$\text{Gain}(s_i) = \alpha \cdot \Delta \text{ROUGE-L}_{\text{Recall}} + (1 - \alpha) \cdot \Delta \text{BERTScore} \quad (1)$$

Trong đó:

- $\Delta \text{ROUGE-L}_{\text{Recall}}$: mức tăng của ROUGE-L Recall khi thêm câu s_i vào tập tóm tắt hiện tại.
- $\Delta \text{BERTScore}$: mức tăng BERTScore tương ứng.
- $\alpha \in [0, 1]$: hệ số cân bằng giữa độ bao phủ từ vựng và tương đồng ngữ nghĩa.

Thiết kế này cho phép mô hình đồng thời ưu tiên các câu chứa thông tin quan trọng và các câu mang ý nghĩa tương đương dù không trùng khớp từ ngữ.

3.1.3. Chiến thuật gán nhãn Greedy. Dựa trên hàm Gain, chúng tôi áp dụng thuật toán tham lam (greedy selection) để xây dựng tập câu extractive S .

Quy trình được thực hiện như sau:

- 1) Khởi tạo $S = \emptyset$.
- 2) Lặp:
 - Với mỗi câu chưa được chọn s_i , tính $\text{Gain}(s_i)$.
 - Chọn câu có Gain lớn nhất.
 - Thêm câu đó vào S nếu $\text{Gain} > 0$.
- 3) Dừng khi không còn câu nào làm tăng giá trị đánh giá hoặc đạt giới hạn số câu.

Sau khi hoàn tất quá trình chọn câu, tập câu extractive được chuyển thành vector nhị phân:

$$\mathbf{y} = [y_1, y_2, \dots, y_n], \quad y_i = \begin{cases} 1, & \text{nếu câu } s_i \in S \\ 0, & \text{ngược lại} \end{cases} \quad (2)$$

Trong đó:

- $y_i = 1$: câu được chọn (positive sample).
- $y_i = 0$: câu không được chọn (negative sample).

3.1.4. BiLSTM-based Extractive Model. Với BiLSTM, mỗi câu được biểu diễn dưới dạng chuỗi embedding từ $x_i = \{w_{i,1}, w_{i,2}, \dots, w_{i,T}\}$

LSTM xuôi và ngược được định nghĩa như sau:

$$\vec{\mathbf{h}}_t = \text{LSTM}_f(\mathbf{w}_t, \vec{\mathbf{h}}_{t-1}), \quad \overleftarrow{\mathbf{h}}_t = \text{LSTM}_b(\mathbf{w}_t, \overleftarrow{\mathbf{h}}_{t+1}) \quad (3)$$

Biểu diễn câu được lấy bằng cách nối hai trạng thái cuối:

$$\mathbf{h}_i = [\vec{\mathbf{h}}_T; \overleftarrow{\mathbf{h}}_1] \quad (4)$$

Sau đó, xác suất câu được chọn được tính bằng:

$$p_i = \sigma(\mathbf{W}\mathbf{h}_i + b) \quad (5)$$

3.1.5. BiGRU-based Extractive Model. Các cổng GRU được định nghĩa như sau:

$$\mathbf{z}_t = \sigma(\mathbf{W}_z \mathbf{w}_t + \mathbf{U}_z \mathbf{h}_{t-1}) \quad (6)$$


$$\mathbf{r}_t = \sigma(\mathbf{W}_r \mathbf{w}_t + \mathbf{U}_r \mathbf{h}_{t-1}) \quad (7)$$

$$\tilde{\mathbf{h}}_t = \tanh(\mathbf{W}_h \mathbf{w}_t + \mathbf{U}_h (\mathbf{r}_t \odot \mathbf{h}_{t-1})) \quad (8)$$


$$\mathbf{h}_t = (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t \quad (9)$$

Biểu diễn câu và hàm dự đoán được giữ nguyên như BiLSTM:

$$\mathbf{h}_i = [\vec{\mathbf{h}}_T; \overleftarrow{\mathbf{h}}_1], \quad p_i = \sigma(\mathbf{W}\mathbf{h}_i + b) \quad (10)$$



(a) BiLSTM architecture



(b) BiGRU architecture

Hình 1: RNN-based architectures

3.1.6. PhoBERT-based Extractive Model. Khác với các mô hình RNN, PhoBERT là mô hình Transformer được huấn luyện trước trên corpora tiếng Việt quy mô lớn, cho phép nắm bắt ngữ cảnh sâu và quan hệ dài hạn.

Với mỗi câu s_i , đầu vào được biểu diễn dưới dạng:


$$\mathbf{H}_i = \text{PhoBERT}(s_i) \quad (11)$$

Trong đó: $\mathbf{H}_i \in \mathbb{R}^{T \times d}$ là các hidden states. Biểu diễn câu được lấy từ token CLS.

$$\mathbf{h}_i = \mathbf{H}_i^{[\text{CLS}]} \quad (12)$$

Xác suất câu được chọn được tính tương tự:

$$p_i = \sigma(\mathbf{W}\mathbf{h}_i + b) \quad (13)$$



Hình 2: BERT architecture

3.1.7. Hàm mất mát (Loss Function). Tất cả các mô hình extractive đều được huấn luyện bằng **Binary Cross-Entropy Loss**, dựa trên nhãn giả y_i thu được từ chiến lược greedy:

$$\mathcal{L}_{\text{ext}} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)] \quad (14)$$

3.2. Abstractive Module

Sau khi lựa chọn các câu quan trọng ở giai đoạn extractive, bài toán được chuyển sang giai đoạn **abstractive summarization**, với mục tiêu sinh ra một đoạn tóm tắt **mạch lạc, trôi chảy và mang tính diễn đạt lại**, thay vì chỉ nối các câu trích xuất.

Trong nghiên cứu này, chúng tôi sử dụng **ViT5**, một mô hình Seq2Seq dựa trên kiến trúc Transformer, được tiền huấn luyện chuyên biệt cho tiếng Việt. ViT5 kế thừa thiết kế của T5 (*Text-to-Text Transfer Transformer*), trong đó mọi tác vụ NLP đều được biểu diễn dưới dạng ánh xạ từ chuỗi văn bản đầu vào sang chuỗi văn bản đầu ra.

3.2.1. Biểu diễn đầu vào. Đầu vào của mô hình ViT5 là phép nối các câu được chọn từ module extractive:

$$\mathbf{X} = \text{Concat}(s_{i_1}, s_{i_2}, \dots, s_{i_k}) \quad (15)$$

Trong đó:

- s_{i_j} là các câu được chọn ($y_{i_j} = 1$)
- k là số câu *extractive*
- $\mathbf{X}$ đóng vai trò như một bản thảo ban đầu (*draft*) cho quá trình sinh tóm tắt

3.2.2. Encoder của ViT5. Encoder của ViT5 bao gồm L lớp Transformer encoder, mỗi lớp sử dụng self-attention để mã hóa ngữ cảnh toàn cục:

$$\mathbf{H}^{(l)} = \text{TransformerEnc}^{(l)}(\mathbf{H}^{(l-1)}), \quad l = 1, \dots, L \quad (16)$$

Trong đó:

- $\mathbf{H}^{(0)} = \mathbf{E}$
- $\mathbf{H}^{(L)}$ là biểu diễn ngữ nghĩa cuối cùng của chuỗi đầu vào

Cơ chế self-attention được tính như sau:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V \quad (17)$$

3.2.3. Decoder và quá trình sinh chuỗi. Decoder của ViT5 sinh ra chuỗi tóm tắt từng token một cách tự hồi quy. Tại bước thời gian t , xác suất sinh token y_t được định nghĩa:

$$P(y_t | y_{<t}, X) = \text{softmax}(\mathbf{W}_o \mathbf{h}_t + b_o) \quad (18)$$


Trong đó:

- $\mathbf{h}_t$ là hidden state của decoder tại bước t .
- Decoder sử dụng masked self-attention và cross-attention với encoder

3.2.4. Hàm mất mát huấn luyện. ViT5 được huấn luyện bằng **Negative Log-Likelihood Loss (tương đương Cross-Entropy)** trên chuỗi tóm tắt tham chiếu $Y = \{y_1, \dots, y_T\}$:

$$\mathcal{L}_{\text{abs}} = - \sum_{t=1}^T \log P(y_t | y_{<t}, X) \quad (19)$$

Hàm loss này khuyến khích mô hình sinh ra các chuỗi có xác suất cao nhất so với summary tham chiếu, đồng thời tận dụng khả năng sinh ngôn ngữ tự nhiên của ViT5.



Hình 3: T5 architecture

3.3. Evaluator & Iterative Refinement

Lấy cảm hứng từ công trình *Summit: Iterative Text Summarization via ChatGPT*, nghiên cứu này áp dụng cơ chế **iterative refinement**, trong đó chất lượng bản tóm tắt được cải thiện dần thông qua nhiều vòng đánh giá và chỉnh sửa. Tuy nhiên, khác với Summit sử dụng **LLM-LLM**, hệ thống đề xuất áp dụng kiến trúc **LLM-SLM**, trong đó:

- **ViT5** đóng vai trò bộ sinh tóm tắt (generator),
- **LLM** đóng vai trò evaluator, chịu trách nhiệm đánh giá, điều phối hành động tinh chỉnh không tham gia trực tiếp vào quá trình tóm tắt.

Tại mỗi vòng lặp t , evaluator chỉ được phép thực hiện **chính xác một hành động**, theo không gian hành động rời rạc:

$$a^{(t)} \in \{\text{REMOVE}, \text{ADD}, \text{STOP}\} \quad (20)$$

Ý nghĩa các hành động được định nghĩa như sau:

- **REMOVE:** loại bỏ các câu trong bản tóm tắt hiện tại bị đánh giá là nhiễu, dư thừa hoặc kém liên quan.
- **ADD:** bổ sung thêm thông tin bằng cách mở rộng tập câu đầu vào cho ViT5 với top-k câu có xác suất cao nhất từ module extractive nhưng chưa được sử dụng.
- **STOP:** kết thúc quá trình tinh chỉnh khi bản tóm tắt được đánh giá là đạt chất lượng mong muốn.

Đồng thời cũng tránh hiện tượng over-refinement, số vòng lặp được giới hạn số lần là 3.

3.3.1. Quy trình Iterative Refinement. Tại vòng lặp thứ t , hệ thống duy trì trạng thái gồm:

- bản tóm tắt hiện tại Y^t
- tập câu đầu vào X^t

Evaluator nhận vào cặp (X^t, Y^t) và đưa ra hành động:

$$a^{(t)} = \text{Evaluator}(X^{(t)}, Y^{(t)}) \quad (21)$$

Quá trình cập nhật trạng thái được mô tả như sau:

- **REMOVE:**

$$X^{(t+1)} = X^{(t)} \setminus \mathcal{R}^{(t)} \quad (22)$$

- **ADD:**

$$X^{(t+1)} = X^{(t)} \cup \mathcal{A}^{(t)} \quad (23)$$

- **STOP:**

$$X^{(t+1)} = X^{(t)}, \quad Y^{(t+1)} = Y^{(t)} \quad (24)$$

Sau mỗi hành động **REMOVE** hoặc **ADD**, mô hình **ViT5** được gọi lại để sinh bản tóm tắt mới:

$$Y^{(t+1)} = \text{ViT5}(X^{(t+1)}) \quad (25)$$

3.4. Tiêu chí đánh giá của Evaluator

Evaluator dựa trên LLM đánh giá bản tóm tắt theo các tiêu chí ngữ nghĩa cấp cao, bao gồm:

- **Coverage:** mức độ bao phủ thông tin quan trọng so với văn bản gốc,
- **Faithfulness:** mức độ trung thực, tránh hallucination,
- **Coherence:** độ mạch lạc và trôi chảy của văn bản sinh
- **Relevance:** Đánh giá mức độ liên quan của các câu trong bản tóm tắt đối với mục tiêu tóm tắt.
- **Conciseness:** Đo lường khả năng cô đọng thông tin của bản tóm tắt.

Bên cạnh đánh giá chủ quan từ LLM, nghiên cứu còn sử dụng các chỉ số **ROUGE** để đánh giá định lượng, nhằm đảm bảo tính so sánh với các phương pháp tóm tắt truyền thống. Cụ thể, ba biến thể ROUGE được sử dụng:

- **ROUGE-1:** đo độ trùng khớp unigram, phản ánh mức độ bao phủ từ vựng cơ bản.
- **ROUGE-2:** đo độ trùng khớp bigram, phản ánh khả năng bảo toàn cụm từ và ngữ cảnh cục bộ.
- **ROUGE-L:** dựa trên Longest Common Subsequence (LCS), phản ánh mức độ bảo toàn cấu trúc câu.

$$\text{ROUGE-L} = \frac{(1 + \beta^2) \cdot P_{LCS} \cdot R_{LCS}}{R_{LCS} + \beta^2 \cdot P_{LCS}} \quad (26)$$

Mặc dù evaluator không trực tiếp tối ưu một hàm mục tiêu khả vi, quá trình refinement có thể được xem như một xấp xỉ của bài toán tối ưu sau:

$$Y^* = \arg \max_Y Q(Y | X) \quad (27)$$

4. Experimental Results

4.1. Kết quả huấn luyện Extractive Module

Chúng tôi huấn luyện ba mô hình extractive gồm **Bi-LSTM**, **Bi-GRU** và **PhoBERT** trong **3 epoch**, sử dụng nhân giả sinh từ chiến thuật greedy dựa trên ROUGE-L Recall và BERTScore. Bảng kết quả cho thấy hiệu năng phân loại câu (được chọn / không được chọn) của từng mô hình.

Model	Accuracy	Precision	Recall	F1
Bi-LSTM	0.77	0.678	0.811	0.7391
Bi-GRU	0.773	0.686	0.803	0.7399
PhoBERT (3 epoch)	0.714	0.623	0.729	0.672

Bảng 1: So sánh hiệu năng các mô hình trong giai đoạn Extractive.

Bi-GRU đạt **F1-score cao nhất (0.7399)**, nhỉnh hơn Bi-LSTM một mức nhỏ, trong khi PhoBERT cho kết quả thấp hơn đáng kể trên tất cả các chỉ số. Điều này cho thấy trong bối cảnh dữ liệu nhân giả và kích thước huấn luyện hạn chế, các mô hình RNN hai chiều có xu hướng ổn định và phù hợp hơn so với mô hình Transformer lớn.

Đáng chú ý, cả Bi-LSTM và Bi-GRU đều đạt **Recall cao (> 0.80)**, phản ánh khả năng bao phủ tốt các câu quan

trọng, phù hợp với mục tiêu cung cấp tập câu đầu vào giàu thông tin cho Abstractive Module. Ngược lại, PhoBERT có xu hướng thận trọng hơn, dẫn đến Recall thấp và làm suy giảm Coverage ở bước sinh tóm tắt.

4.1.1. Kết quả hệ thống Abstractive Summarization. Hệ thống Abstractive Module sử dụng ViT5 làm mô hình sinh tóm tắt nền, và được đánh giá trong hai thiết lập:

- ViT5 thuần
- ViT5 kết hợp Evaluator & Iterative Refinement.

Metrics	ViT5	Refinement
ROUGE-1	57.7	59.7
ROUGE-2	25.9	28.1
ROUGE-L	36.8	39.4

Bảng 2: Kết quả so sánh giữa mô hình ViT5 và quy trình Refinement dựa trên các chỉ số ROUGE.

4.1.2. Đánh giá tự động (ROUGE). Kết quả ROUGE cho thấy iterative refinement mang lại cải thiện nhất quán trên cả ba chỉ số:

- ROUGE-1 tăng **2.0**, cho thấy mức độ bao phủ unigram được cải thiện rõ rệt.
- ROUGE-2 tăng **2.2**, phản ánh khả năng bảo toàn cụm từ và ngữ cảnh cục bộ tốt hơn.
- ROUGE-L tăng **2.6**, cho thấy cấu trúc và trật tự thông tin của bản tóm tắt gần hơn với tóm tắt tham chiếu.

Sự cải thiện đồng đều này cho thấy evaluator không chỉ tối ưu theo một khía cạnh đơn lẻ mà giúp nâng cao chất lượng tổng thể của bản tóm tắt.

Criterion	ViT5	Refinement
Faithfulness	3.16	3.30
Relevance	2.21	2.27
Coherence	3.91	3.95
Fluency	4.48	4.55
Conciseness	4.29	4.30
Overall	3.61	3.67

Bảng 3: Đánh giá chất lượng bản tóm tắt dựa trên các tiêu chí định tính.

4.1.3. Đánh giá ngữ nghĩa cấp cao (LLM-based). Trên các tiêu chí đánh giá ngữ nghĩa, hệ thống refinement cũng cho thấy xu hướng cải thiện ổn định:

- **Faithfulness** tăng **0.14**, cho thấy cơ chế REMOVE giúp giảm hallucination hiệu quả.
- **Relevance** tăng **0.06**, phản ánh việc loại bỏ các câu gây nhiễu và tập trung hơn vào nội dung cốt lõi.
- **Coherence** và **Fluency** đều tăng nhẹ, cho thấy iterative refinement không làm suy giảm tính mạch lạc hay độ trôi chảy của văn bản.
- **Conciseness** gần như giữ nguyên, cho thấy hệ thống cải thiện chất lượng mà không làm tóm tắt trở nên dài dòng hơn.

Điểm **Overall** tăng từ **3.61** lên **3.67**, xác nhận rằng sự cải thiện không chỉ mang tính cục bộ mà có ý nghĩa trên toàn bộ chất lượng tóm tắt.

5. Conclusion and Future Work

5.1. Conclusion

Trong nghiên cứu này, chúng tôi đề xuất một hệ thống **hybrid extractive–abstractive summarization** cho tin tức tiếng Việt, kết hợp cơ chế **Evaluator & Iterative Refinement** nhằm vượt qua hạn chế của các mô hình tóm tắt một lần truyền thống. Điểm then chốt của hệ thống là việc phân tách rõ vai trò giữa các thành phần: module extractive đảm nhiệm việc chọn lọc thông tin cốt lõi, ViT5 đóng vai trò bộ sinh tóm tắt chính, trong khi LLM được sử dụng như một evaluator ngữ nghĩa để điều phối quá trình tinh chỉnh lặp.

Kết quả thực nghiệm cho thấy chiến lược iterative refinement mang lại cải thiện nhất quán trên cả các chỉ số tự động (ROUGE-1, ROUGE-2, ROUGE-L) và các tiêu chí đánh giá ngữ nghĩa cấp cao như faithfulness, relevance và coherence. Đặc biệt, việc giảm thiểu hallucination trong khi vẫn duy trì độ trôi chảy và tính cô đọng của văn bản cho thấy hiệu quả của cách tiếp cận LLM–SLM so với các mô hình LLM–LLM thuần túy, nhất là trong bối cảnh tiếng Việt và tài nguyên tính toán hạn chế.

5.2. Future Work

Mặc dù đạt được những kết quả tích cực, nghiên cứu này vẫn còn một số hướng mở đáng chú ý. Trước hết, không gian hành động của evaluator hiện được giới hạn ở ba hành động rời rạc (REMOVE, ADD, STOP). Trong tương lai, có thể mở rộng sang các hành động tinh chỉnh tinh vi hơn, chẳng hạn như **REWRITE** hoặc **MERGE**, cho phép chỉnh sửa trực tiếp ở mức câu hoặc cụm câu.

Thứ hai, evaluator hiện hoạt động như một bộ đánh giá ngầm dựa trên suy luận của LLM. Một hướng nghiên cứu tiềm năng là học hóa evaluator, ví dụ bằng cách huấn luyện một mô hình nhỏ hơn mô phỏng quyết định của LLM, nhằm giảm chi phí suy luận và tăng khả năng triển khai thực tế.

Ngoài ra, hệ thống hiện mới được đánh giá trên miền tin tức. Việc mở rộng sang các miền dữ liệu chuyên biệt như y tế, pháp luật hoặc giáo dục, nơi yêu cầu độ chính xác và tính trung thực cao hơn, sẽ là một bước quan trọng để kiểm chứng tính tổng quát của phương pháp. Cuối cùng, việc kết hợp thêm đánh giá của con người (human evaluation) với quy mô lớn hơn sẽ giúp xác nhận sâu hơn mối tương quan giữa đánh giá tự động, LLM-based evaluator và cảm nhận thực tế của người dùng.

Tài liệu

[1] Jiacheng Zhang, Yixin Liu, Jinchao Han, and Xipeng Sun, *SummIt: Iterative Text Summarization via ChatGPT*, arXiv preprint arXiv:2305.14835, 2023.

[2] Alexander R. Fabbri, Wojciech Kryściński, Bryan McCann, Caiming Xiong, and Dragomir R. Radev, *Understanding the Extent to which Summarization Evaluation Metrics Measure the Information Quality of Summaries*, arXiv preprint arXiv:2010.12495, 2020.

[3] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov, *A Unified Model for Extractive and Abstractive Summarization using Inconsistency Loss*, in Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL), 2018.

[4] Jiacheng Zhang, Yixin Liu, and Xipeng Sun, *Text Summarization with Oracle Expectation*, arXiv preprint arXiv:2209.12714, 2022.

[5] Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q. Weinberger, and Yoav Artzi, *BERTScore: Evaluating Text Generation with BERT*, in Proceedings of the 7th International Conference on Learning Representations (ICLR), 2019.